

Estatística

Sérgio Manuel Salazar dos Santos, N^o: 1020881

20 de Dezembro de 2019

Conteúdo

| | | |
|------|--|---|
| .1 | Introdução | 1 |
| .2 | O conjunto de dados | 1 |
| .3 | Metodologia Estatística | 4 |
| .3.1 | Índice de Confiança tempo médio TEE | 4 |
| .3.2 | Verificar diferença de valores num intervalo | 4 |
| .3.3 | Verificar diferenças entre as regiões | 5 |
| .4 | Resultados e interpretação | 6 |
| .5 | Conclusões | 6 |

Resumo

Este trabalho consiste no estudo de Estatística das Entregas Expresso em duas regiões **A** e **B**, as variáveis em estudo é o tempo de demora das entregas e a variável de número de encomendas entregues num determinado unidade de tempo [u.t.]. Nestas situações foram retiradas 120 e 90 amostras nas duas regiões respectivamente. A primeira é uma distribuição contínua, o tempo, e a segunda uma distribuição discreta.

As matérias abordadas vão ser **Amostragem**, **Estimação de parâmetros** e **Testes de Hipóteses**

.1 Introdução

As variáveis consideradas são:

- Região (REG): variável nominal com dois níveis
Região A
Região B
- Tempo de entrega (TEE), por encomenda: Variável expressa em u.t.
- Número de encomendas entregues (NEE) por u.t.

Admitindo que a amostra disponível é uma amostra aleatória representativa das populações.

Neste relatório esta-se a trabalhar com duas grandezas precisamente o tempo (TEE) e quantidade por u.t (NEE), temos recolhidos 120 registos **TEE** na qual pela regra de sturges $c = \text{int}(1 + 3.3\log(n))$, determina-se que é necessário sete [7] classes.

Podemos obter a amplitude de cada classe $h = b - a$ e sua marca $x_i = \frac{a+b}{2}$.

.2 O conjunto de dados

X_{iA} - "Variável aleatória que representa o tempo de demora na Região **A** da entrega de uma encomenda Expresso em u.t." $i=1,2,3, \dots, 120$

X_{iB} - "Variável aleatória que representa o tempo de demora na Região **B** da entrega de uma encomenda Expresso em u.t." $i=1,2,3, \dots, 120$

Abaixo o resultado da tabela TEE:

| h_i | CLASSE | MARCA | n_{iA} | n_{iB} | $\frac{n_{iA}}{h_i}$ | $\frac{n_{iB}}{h_i}$ | f_{iA} | f_{iB} | F_{iA} | F_{iB} |
|-------|---------|-------|----------|----------|----------------------|----------------------|----------|----------|----------|----------|
| 4 | [5,10[| 7,5 | 8 | 1 | 2 | 0,25 | 0,0667 | 0,0083 | 0,0667 | 0,0083 |
| 4 | [10,15[| 12,5 | 16 | 18 | 4 | 4,5 | 0,1333 | 0,15 | 0,2 | 0,1583 |
| 4 | [15,20[| 17,5 | 40 | 28 | 10 | 7 | 0,3333 | 0,2333 | 0,5333 | 0,3917 |
| 4 | [20,25[| 22,5 | 25 | 41 | 6,25 | 10,25 | 0,2083 | 0,3417 | 0,7417 | 0,7333 |
| 4 | [25,30[| 27,5 | 26 | 22 | 6,5 | 5,5 | 0,2167 | 0,1833 | 0,9583 | 0,9167 |
| 4 | [30,35[| 32,5 | 4 | 8 | 1 | 2 | 0,0333 | 0,0667 | 0,9917 | 0,9833 |
| 5 | [35,40] | 37,5 | 1 | 2 | 0,2 | 0,4 | 0,0083 | 0,0167 | 1 | 1 |
| | | | n=120 | n=120 | | | | | | |

n_i - frequência absoluta f_i - frequência relativa F_i - frequência acumulada

Recorrendo ao excel obteve-se os seguintes resultados:

| | |
|---|--|
| Média aritmética dados classificados | Variância de uma amostra dados classificados |
| $\bar{x} = \frac{1}{n} \sum_{i=1}^c x_i n_i = \sum_{i=1}^c x_i f_i$ | $s^2 = \frac{1}{n-1} \sum_{i=1}^c (x_i - \bar{x})^2 n_i$ |

| Estatística | X_A | X_B |
|------------------------|---------|---------|
| Mínimo | 7,5 | 7,5 |
| Q_1 :1º Quartil | 17,5 | 17,5 |
| m_d : mediana | 17,5 | 22,5 |
| Q_3 :3º Quartil | 27,5 | 27,5 |
| Máximo | 37,5 | 37,5 |
| \bar{X} : Média | 20,0417 | 21,5417 |
| s : desvio-padrão | 6,4494 | 6,0909 |
| m_o : moda | 17,5 | 22,5 |
| Tamanho amostral $[n]$ | 120 | 120 |




Figura 1: TEE

Na Região **A** a Média > Moda = Mediana
com skew = -0,1051 e kurt = -0,4016
Na Região **B** a Média < Moda = Mediana
com skew = 0,1119 e kurt = -0,1835

Na prática, considera-se que a qualidade da aproximação é suficientemente boa quando $n \geq 30$.
Pode-se tomar que $\delta \cong s$.

$$\left\{ \begin{array}{l} \mu \\ \delta \end{array} \right\} \Rightarrow \bar{X} = \frac{\sum_{i=1}^n X_i}{n} \sim N\left(\mu; \frac{\delta^2}{n}\right)$$

$$\begin{array}{ll} \bar{x}_{A_0} = 20,0417 & \bar{x}_{B_0} = 21,5417 \\ \delta_A = 6,4494 & \delta_B = 6,0909 \end{array}$$

Tratamento dos dados da Segunda Variável Aleatória

Y_{iA} - "Variável aleatória que representa o número de encomendas entregues pela Expresso na Região **A** por u.t."
 $i=1,2,3, \dots, 90$

Y_{iB} - "Variável aleatória que representa o número de encomendas entregues pela Expresso na Região **B** por u.t."
 $i=1,2,3, \dots, 90$

Abaixo o resultado da tabela NEE:

| Y_i | n_{iA} | n_{iB} | f_{iA} | f_{iB} | F_{iA} | F_{iB} |
|-------|----------|----------|----------|----------|----------|----------|
| 3 | 6 | 3 | 0,0667 | 0,0333 | 0,0667 | 0,0333 |
| 4 | 8 | 6 | 0,0889 | 0,0667 | 0,1556 | 0,1 |
| 5 | 19 | 13 | 0,2111 | 0,1444 | 0,3677 | 0,2444 |
| 6 | 15 | 7 | 0,1667 | 0,0778 | 0,5333 | 0,3222 |
| 7 | 13 | 19 | 0,1444 | 0,2111 | 0,6778 | 0,5333 |
| 8 | 11 | 15 | 0,1222 | 0,1667 | 0,8 | 0,7 |
| 9 | 6 | 8 | 0,0667 | 0,0889 | 0,8667 | 0,7889 |
| 10 | 5 | 11 | 0,0556 | 0,1222 | 0,9222 | 0,9111 |
| 11 | 4 | 3 | 0,0444 | 0,0333 | 0,9667 | 0,9444 |
| 12 | 0 | 2 | 0 | 0,0222 | 0,9667 | 0,9667 |
| 13 | 2 | 1 | 0,0222 | 0,0111 | 0,9889 | 0,9778 |
| 14 | 1 | 0 | 0,0111 | 0 | 1 | 0,9778 |
| 15 | 0 | 1 | 0 | 0,0111 | 1 | 0,9889 |
| 16 | 0 | 1 | 0 | 0,0111 | 1 | 1 |

| Estatística | Y_A | Y_B |
|------------------------|--------|--------|
| Mínimo | 3 | 3 |
| Q_1 :1º Quartil | 5 | 6 |
| m_d : mediana | 6 | 7 |
| Q_3 :3º Quartil | 8 | 9 |
| Máximo | 14 | 16 |
| \bar{Y} : Média | 6,6111 | 7,5111 |
| s : desvio-padrão | 2,3112 | 2,5140 |
| m_o : moda | 5 | 7 |
| Tamanho amostral $[n]$ | 90 | 90 |




Figura 2: NEE

Na Região **A** a Média > Mediana > Moda
com skew = 0.74553 e kurt = 0.49789

Na Região **B** a Média > Mediana = Moda
com skew = 0.67659 e kurt = 1.01076

$$\begin{cases} \mu \\ \delta \end{cases} \implies \bar{Y} = \frac{\sum_{i=1}^n Y_i}{n} \sim N\left(\mu; \frac{\delta^2}{n}\right)$$

$$\begin{aligned} \bar{y}_{A_0} &= 6,6111 & \bar{y}_{B_0} &= 7,5111 \\ \delta_A &= 2,3112 & \delta_B &= 2,5140 \end{aligned}$$

Na tabela acima a mediana e a moda são estimativas aproximadas, apenas nos dá uma dica na qual está na classe representativa.

A mediana pode ser obtida pela frequência acumulativa quando esta é igual a 50%, ou seja, $F_i(\text{Mediana}) = 0,5$

A Moda mais facilmente identificada pelo seu pico máximo na lista de amostras.

.3 Metodologia Estatística

.3.1 Índice de Confiança tempo médio TEE

Estimação do tempo médio para as regiões **A** e **B** com um índice de confiança de 95%.

$$IC_{1-\alpha} = [A, B]; \text{ para } 1 - \alpha = 0.95, \alpha = 0.05, \frac{\alpha}{2} = 0.025$$

$$\text{Zona critica } Z_c = Z_{1-\frac{\alpha}{2}} = \Phi^{-1}(0.975) \cong 1.96$$

$$P(A \leq \mu \leq B) = 1 - \alpha$$

$$\Delta = Z_c \times \frac{\delta}{\sqrt{n}}$$

$$A = \bar{x} - \Delta \quad \text{and} \quad B = \bar{x} + \Delta$$

\therefore

$$IC_{A_{0.95}} = [18.8877, 21.1956] \quad \text{and} \quad IC_{B_{0.95}} = [20.4519, 22.6314]$$

Pode-se estimar que o tempo médio $[\mu]$ de entrega na população esta dentro dos intervalos acima mencionados com 95% de confiança.

.3.2 Verificar diferença de valores num intervalo

Verificar se os dados permitem afirmar que existe diferença significativa entre a % de períodos com menos de 6 entregas por u.t. na região **A** e na região **B**. Responda com base num intervalo de confiança de 97%.

Distribuição discreta:

$$\bar{y}_{A_0} = 6,6111 \quad \bar{y}_{B_0} = 7,5111 \quad n = 90$$

$$\delta_A = 2,3112 \quad \delta_B = 2,5140$$

$$\left\{ \begin{array}{l} \mu \\ \delta \end{array} \right\} \implies \bar{Y} = \frac{\sum_{i=1}^n Y_i}{n} \sim N\left(\mu; \frac{\delta^2}{n}\right)$$

$$P(Y_A < 6) = P(Y_A \leq 5) = F_{i_B}(5) \cong 0,3677 \quad \text{e} \quad P(Y_B < 6) = P(Y_B \leq 5) = F_{i_B}(5) \cong 0,2444$$

$$\hat{P}_A - \hat{P}_B \sim N\left(p_A - p_B; \frac{p_A q_A}{n_A} + \frac{p_B q_B}{n_B}\right) \quad \Delta = z_{(1-\frac{\alpha}{2})} \sqrt{\frac{\hat{p}_A \hat{q}_A}{n_A} + \frac{\hat{p}_B \hat{q}_B}{n_B}} \quad q = (1 - p)$$

$$IC_{97\%}(\hat{P}_A - \hat{P}_B) = [(\hat{p}_A - \hat{p}_B) - \Delta; (\hat{p}_A - \hat{p}_B) + \Delta]$$

$$\hat{P}_A - \hat{P}_B \sim N(0,1233; 0,02788) \quad z_{(1-\frac{\alpha}{2})} = \phi^{-1}(0,985) = 2,1701$$

Recorrendo a calculadora casio $fx - 9860GII$:

$$\Delta = InvNorm(0.985) \sqrt{\frac{0.3677(1-0.3677)}{90} + \frac{0.2444(1-0.2444)}{90}} \cong 0.3677$$

\therefore

$$IC_{97\%}(\hat{P}_A - \hat{P}_B) = [(\hat{p}_A - \hat{p}_B) - 0,3624; (\hat{p}_A - \hat{p}_B) + 0,3624]$$

A Diferença de proporção tem um erro de 36,24%.

.3.3 Verificar diferenças entre as regiões

Testar se a região (REG) tem um efeito estatisticamente significativo sobre TEE e NEE ao nível de diferença de médias. Considere uma significância à sua escolha inferior ou igual a 5%. Use o critério do valor de prova para fundamentar a decisão.

$$\begin{cases} H_0 : & \mu_A - \mu_B = 0 \\ H_1 : & \mu_A - \mu_B < 0 \end{cases}$$

Condição TEE:

$$\begin{cases} \mu = 0 \\ \delta = s \end{cases} \implies \bar{X}_A - \bar{X}_B \sim N\left(0, \frac{\delta_A^2}{n_A} + \frac{\delta_B^2}{n_B}\right)$$

$$z_0 = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{\delta_A^2}{n_A} + \frac{\delta_B^2}{n_B}}} \quad RC_z =]-\infty, -z_{1-\alpha}] \quad pvalue = P(Z < z_0)$$

Condição REE:

$$\begin{aligned} & \frac{\bar{y}_A - \bar{y}_B}{\sqrt{\frac{\delta_A^2}{n_A} + \frac{\delta_B^2}{n_B}}} \\ z_0 &= \frac{\bar{y}_A - \bar{y}_B}{\sqrt{\frac{\delta_A^2}{n_A} + \frac{\delta_B^2}{n_B}}} \\ RC_z &=]-\infty, -z_{1-\alpha}] \\ pvalue &= P(Z < z_0) \end{aligned}$$

.4 Resultados e interpretação

fazer tabela só com resultados

.5 Conclusões

A Distribuição normal tem a Média = Mediana = Moda, devido a ter uma distribuição simétrica, quando estamos a analisar valores discretos isto não acontece devido a não ser simétrico podendo ter vários casos diferentes, e quanto menor o número de amostras da população maior a dificuldade de se poder inferir e estimar valores.

Lista de Figuras

| | | |
|----|---------------|---|
| 1 | TEE | 2 |
| 2 | NEE | 3 |
| [] | | |

Bibliografia

- [1] *Probabilidades e estatística Volume 1*. McGraw-Hill, 1990.
- [2] *Probabilidades e Processos Estocásticos*. Universidade de Aveiro, 2002.

1