

Estatística (ESTAT)

2019/2020

LEEC

C2B – Distribuições de probabilidade (2ª parte)
Distribuições contínuas

VARIÁVEIS ALEATÓRIA CONTÍNUAS

- Uma v.a contínua pode assumir qualquer valor dentro de um intervalo de números reais. Consequentemente o conjunto de valores que pode assumir (contradomínio) é não numerável
- Não é possível listar, individualmente, todos os possíveis valores de uma variável aleatória contínua. Por conseguinte o quadro de distribuição de probabilidade/função de probabilidade é inadequada para descrever convenientemente a v.a.
- Associam-se probabilidades a intervalos da variável e não a pontos.

FUNÇÃO DENSIDADE DE PROBABILIDADE

Uma v.a. X contínua é caracterizada pela sua função densidade de probabilidade $f(x)$ com as seguintes propriedades:


i) $f(x) \geq 0$, para todo x ;

ii) A área sob limitada pelo eixo dos xx e a curva de $f(x)$ é 1; ou seja

$$\int_{-\infty}^{+\infty} f(x)dx = 1$$

iii) $P(a \leq X \leq b) =$ área sob a curva de $f(x)$ e acima do eixo x , entre os pontos a e b , ou seja

$$P(a \leq X \leq b) = \int_a^b f(x)dx$$



iv) $P(X = x_0) = 0$, para x_0 constante


$$P(X = x_0) = P(x_0 \leq X \leq x_0) = \int_{x_0}^{x_0} f(x)dx = 0$$

Assim, $P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b)$.

FUNÇÃO DENSIDADE DE PROBABILIDADE

Exemplo 1: Um gerador de números aleatórios produz um número real entre 0 e 60 minutos.

A v.a. X que representa o número assim obtido tem a função densidade de probabilidade representada na figura seguinte



a) Determine o valor de k :

Sabe-se que $\int_{-\infty}^{+\infty} f(x)dx = 1$, ou seja,

$$Area = 60k = 1$$


$$k = \frac{1}{60}$$

b) Calcule $P(20 < X < 40)$

$$P(20 < X < 40) = \int_{20}^{40} f(x)dx = \int_{20}^{40} \frac{1}{60} dx \approx 0.33$$

ou

$$P(20 < X < 40) = Area \quad \text{onde} \quad Area = (40 - 20) \cdot \frac{1}{60} \approx 0.33$$



FUNÇÃO DISTRIBUIÇÃO DE PROBABILIDADE

Def: Seja X uma v.a contínua então, a função de distribuição de probabilidade $F(x)$ é

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

Por conseguinte, $f(x) = \frac{d}{dx}F(x)$ nos pontos onde $F(x)$ é derivável.

Verifica-se também que


$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b) = F(b) - F(a),$$

pois é sabido que

$$P(X = x_0) = 0 \quad \text{se} \quad x_0 \text{ é constante.}$$

FUNÇÃO DISTRIBUIÇÃO DE PROBABILIDADE

Retomando o exemplo anterior, cuja v.a. tem função densidade de probabilidade com a representação



$$f(x) = \begin{cases} 1/60 & \text{se } x \in [0, 60] \\ 0 & \text{se } x \notin [0, 60] \end{cases}$$

Cálculo de $F(x)$


$$\text{se } x < 0 \text{ então } F(x) = P(X \leq x) = \int_{-\infty}^x 0 dt = 0$$

$$\text{se } 0 \leq x < 60 \text{ então } F(x) = \int_{-\infty}^0 0 dx + \int_0^x \frac{1}{60} dt = \frac{1}{60}x$$

$$\text{se } x \geq 60 \text{ então } F(x) = 1$$

$$\text{Cálculo: } P(20 < X < 40) = F(40) - F(20) = 20/60 = 1/3$$

$$\text{Cálculo: } P(X > 10) = 1 - F(10) = 1 - (10/60) = 5/6$$



$$F(x) = \begin{cases} 0 & \text{se } x < 0 \\ \frac{1}{60}x & \text{se } 0 \leq x < 60 \\ 1 & \text{se } x \geq 60 \end{cases}$$

VALOR MÉDIO E VARIÂNCIA

Seja X uma v.a. contínua com função densidade de probabilidade $f(x)$, então

O valor médio é a quantidade

$$\mu = E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

A variância é dada por

$$\sigma^2 = V(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

As propriedades são análogas às do caso discreto.

Distribuição Uniforme – $\text{Un}(a, b)$

A distribuição uniforme é usada para representar uma quantidade que varia aleatoriamente num intervalo $[a, b]$ e cuja probabilidade de tomar valores num sub-intervalo de $[a, b]$ é proporcional ao seu comprimento.


Se uma v.a. X tem distribuição uniforme entre a e b , escrevemos simbolicamente, $X \sim \text{Un}(a, b)$.

Como, neste caso, a probabilidade de X de tomar valores num sub-intervalo de $[a, b]$ é proporcional ao comprimento desse intervalo então a f.d.p. de X é constante em $[a, b]$

Distribuição Uniforme – Un(a, b)


Função Densidade de Probabilidade

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$



Função de Distribuição Acumulada

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & x \in [a, b] \\ 1, & x > b \end{cases}$$



Distribuição Uniforme – $U(a, b)$

Propriedades

- Tem 2 parâmetros a e b (se a um parâmetro de localização, $b - a$ é um parâmetro de escala)
- Gama de valores: $[a, b]$
- Média:

$$E(X) = \mu = \frac{a + b}{2}$$

- Variância:

$$V(X) = \frac{(b - a)^2}{12}$$

Distribuição Exponencial– $\text{Exp}(\lambda)$

A distribuição **exponencial** é usada em situações em que se consegue identificar um processo de Poisson. É usada para representar intervalos de tempo entre eventos independentes num processo de Poisson, por exemplo:

- o tempo entre a chegada de duas encomendas a um armazém
- o tempo que decorre entre duas avarias de uma máquina. Tempo de duração de uma lâmpada, etc...

Distribuição Exponencial– $\text{Exp}(\lambda)$

Com efeito,

Se

Y – "número de chegadas, por unidade de tempo" tem distribuição $Po(\lambda)$

então

W – "número de chegadas, por x unidades de tempo" tem distribuição $Po(\lambda x)$ e

$$P(W = w) = f(w) = e^{-\lambda x} \frac{(\lambda x)^w}{w!}$$

Considerando agora, X – "Tempo até uma chegada, em unidades de tempo" vem

$$P(X > x) = P(W = 0) = f(0) = e^{-\lambda x}$$

$$P(T \leq x) = F(x) = 1 - e^{-\lambda x}$$

A função densidade de probabilidade é


$$f(x) = \frac{d}{dx} F(x) = \lambda e^{-\lambda x}, x \geq 0$$

Distribuição Exponencial– $\text{Exp}(\lambda)$

Def: Se $X \sim \text{Exp}(\lambda)$ ($\lambda > 0$) então:


A. A função densidade de probabilidade é:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$



B. A função de distribuição é:

$$F(x) = P(X \leq x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$



Distribuição Exponencial

Algumas propriedades:

Gama de valores: $[0, +\infty[$

Média: $E(X) = \mu = \frac{1}{\lambda}$

Variância: $V(X) = \sigma^2 = \frac{1}{\lambda^2}$

A distribuição exponencial não considera o “desgaste”. Não tem memória,

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t)$$

Distribuição Exponencial

A **distribuição exponencial** pode ser interpretada como o tempo de espera entre dois acontecimentos de **Poisson**.

$$W \sim \text{Po}(\lambda) \Rightarrow E(W) = \lambda$$

$$X \sim \text{Exp}(\lambda) \Rightarrow E(X) = 1/\lambda$$

Ou seja, numa distribuição exponencial o tempo médio de espera entre dois registos sucessivos de um processo de Poisson é o inverso do ritmo médio desses registos.

Distribuição Exponencial

Exemplo:

O tempo de duração de um componente eletrónico A tem distribuição exponencial de média 2500 horas.

- a) Calcule a percentagem de componentes cuja duração excede 2500 horas.
- b) Calcule a probabilidade de um componente durar entre 2500 e 3000 horas.
- c) Calcule o tempo de duração que excedido apenas por 10% dos componentes.

Distribuição Normal – $N(\mu, \sigma^2)$

A distribuição normal é em muitos sentidos a distribuição fundamental da teoria estatística moderna. Foi estudada inicialmente no sec XVIII quando os cientistas observaram um impressionante grau de regularidade nos erros de medição. Naquele tempo verificou-se que os padrões (distribuições) podiam ser aproximados por curvas contínuas a que chamavam “curvas normais dos erros”.

- As propriedades matemáticas das “curvas normais” foram estudadas por Abraham de Moivre (1667-1745), Pierre Laplace (1749-1827) e Karl Gauss (1777-1855).

Distribuição Normal – $N(\mu, \sigma^2)$

A distribuição normal pode ser usada para representar quantidades que resultam da soma de um grande número de quantidades aleatórias (Teorema do Limite Central), ou para representar características de populações associadas a medições e/ou respectivos erros associados. Trata-se de uma distribuição importante dada a sua aplicabilidade na modelização estocástica de muitos fenómenos naturais.

Def: Diz-se que uma

v.a. X tem distribuição normal com parâmetros média μ e variância σ^2 e representa-se simbolicamente

$$X \sim N(\mu, \sigma^2)$$

Se e só se a sua função de densidade é

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad x \in R$$



Distribuição Normal – $N(\mu, \sigma^2)$

Função Densidade de Probabilidade

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad x \in R$$

Função de Distribuição Acumulada


$$F(x) = P(X \leq x) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^x e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt$$



Distribuição Normal – $N(\mu, \sigma^2)$


Algumas características da f.d.p. Normal:

- O domínio é \mathbb{R}
- Tem a forma de sino e um **único máximo** em $x=\mu$
- É **simétrica** relativamente a um eixo vertical em $x=\mu$ (média), a mediana também ocorre em $x=\mu$
- Tem dois **pontos de inflexão** em $x=\mu-\sigma$ e $x=\mu+\sigma$
- o eixo dos xx é uma **assíntota**



Distribuição Normal – $N(\mu, \sigma^2)$

- Cerca de 68% da população difere da média menos de 1 desvio padrão,
 $P(\mu - \sigma < X < \mu + \sigma) \approx 0.6826$
- Cerca de 95% da população difere da média menos de 2 desvios padrões,
 $P(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.9544$
- Cerca de 99.7% da população difere da média menos de 3 desvios padrões,
 $P(\mu - 3\sigma < X < \mu + 3\sigma) \approx 0.9973$



Distribuição Normal – $N(\mu, \sigma^2)$

Propriedades

- Tem como parâmetros μ (localização), σ^2 (escala)
- Gama de valores: $x \in]-\infty, +\infty[$, $\mu \in]-\infty, +\infty[$, $\sigma \in]0, +\infty[$
- Média: $E(X) = \mu$
- Variância: $V(X) = \sigma^2$
- A distribuição $Z \sim N(\mu=0, \sigma^2=1)$ é a Distribuição Normal Reduzida
- se $X \sim N(\mu, \sigma^2)$ e tem-se

$$X = \mu + \sigma Z \sim N(\mu, \sigma^2)$$


e se $Z \sim N(\mu=0, \sigma^2=1)$ então $Z = \frac{X - \mu}{\sigma} \sim N(\mu=0, \sigma^2=1)$

Distribuição Normal Reduzida: Cálculo de probabilidades

Se $Z \sim N(0;1)$ ou seja, Z tem **distribuição normal reduzida** de **média 0** e **variância 1**,

então a sua f.d.p. é $f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$

O valor de $P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz$



não pode ser obtido analiticamente para qualquer z . Existem, contudo, tabelas com valores obtidos por integração numérica da distribuição Normal reduzida.

$$P(Z \leq z) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz \approx \Phi(z)$$

Distribuição Normal Reduzida. Uso da Tabela

Distribuição Normal Reduzida

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du = P(Z \leq z)$$

z	0	1	2	3	4	5	6
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5233
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7122
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8050

a) $P(Z < 0,65) = \Phi(0,65) = 0,7422$

b) $P(Z > 0,24) = 1 - P(Z \leq 0,24) = 1 - \Phi(0,24) = 1 - 0,5948 = 0,4052$


c) $P(0,24 < Z < 0,65) = \Phi(0,65) - \Phi(0,24) = 0,7422 - 0,5948 = 0,1474$

Distribuição Normal Reduzida. Exemplo 1

Seja $Z \sim N(0;1)$

Calcule:

a) $P(Z < 2,13) = \Phi(2,13) = 0,9834$

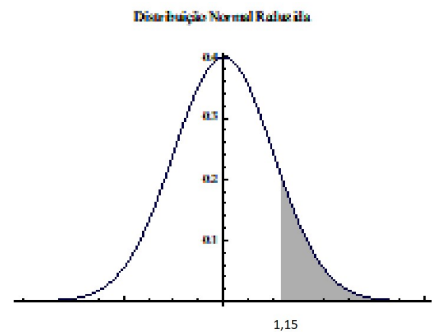


d) Det $k: P(Z < k) = 0,9515$

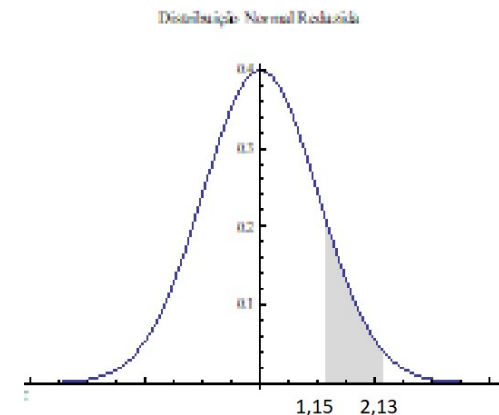
$$\Phi(k) = 0,9515$$

$$k = \Phi^{-1}(0,9515) = 1,66$$

b) $P(Z > 1,15) = 1 - P(Z \leq 1,15) =$
 $1 - \Phi(1,15) = 0,1251$




c) $P(1,15 < Z < 2,13) = P(Z < 2,13) - P(Z < 1,15) =$
 $= \Phi(2,13) - \Phi(1,15) = 0,9834 - 0,8749 = 0,1085$



Distribuição Normal Reduzida: Simetria e cálculo de probabilidades

A distribuição normal reduzida é simétrica relativamente à reta $z=0$



$$P(Z \leq -z) = P(Z > z)$$

$$\Phi(-z) = 1 - P(Z \leq z)$$

$$\Phi(-z) = 1 - \Phi(z)$$

$$\Phi(z) = 1 - \Phi(-z)$$

Distribuição Normal: Cálculo de probabilidades

Suponhamos que $X \sim N(\mu, \sigma^2)$ e que queremos calcular

$$P(a \leq X \leq b) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_a^b e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx$$

A solução deste integral não é conhecida, apenas aproximações numéricas e **tabelas** de áreas sob a curva normal. Estas **tabelas** dão-nos os valores para a distribuição normal reduzida Z .

Teorema: Se $X \sim N(\mu, \sigma^2)$ então $Z = \frac{X - \mu}{\sigma} \sim N(0,1)$

Com o teorema anterior em mente, podemos calcular as probabilidades referentes à v.a. X , a **partir da tabela** que nos dá as probabilidades da v.a. Z

Distribuição Normal: cálculo de probabilidades

$$\text{Se } X \sim N(\mu, \sigma^2) \text{ e } Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$P(X \leq a) = P(Z \leq \frac{a - \mu}{\sigma}) = F(a) = \Phi(\frac{a - \mu}{\sigma})$$

$$P(X > b) = 1 - P(X \leq b) = 1 - F(b) = 1 - \Phi(\frac{b - \mu}{\sigma})$$

Note-se que se utiliza Φ para representar $F(z)$.

$$P(a < X \leq b) = P(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}) = F(b) - F(a) = \Phi(\frac{b - \mu}{\sigma}) - \Phi(\frac{a - \mu}{\sigma})$$

Distribuição Normal. Exemplo 2


Seja $X \sim N(6; 25)$, calcule

a) $P(X < 10)$

$$R: P(X < 10) = P\left(\frac{X - 6}{5} < \frac{10 - 6}{5}\right) = P(Z < 0.8)$$

$$P(Z < 0.8) = \Phi(0.8) \approx 0.7881$$

$$Z = \frac{X - \mu}{\sigma} = \frac{X - 6}{5} \sim N(0; 1)$$



b) $P(X > 5)$

$$R: P(X > 5) = 1 - P(X \leq 5) = 1 - \Phi\left(\frac{5 - 6}{5}\right) = 0.5793 \quad \text{Nota: } P(X < a) = \Phi\left(\frac{a - \mu}{\sigma}\right)$$

c) $P(5 < X < 10)$

$$R: P(5 < X < 10) = P(X < 10) - P(X \leq 5) = 0.7881 - (1 - 0.5793) = 0.3674$$

d) O valor de k que é ultrapassado em 20% dos casos.

$$R: P(X > k) = 0.2 \Leftrightarrow P(X \leq k) = 0.8 \Leftrightarrow \Phi\left(\frac{k - 6}{5}\right) = 0.8 \Leftrightarrow \frac{k - 6}{5} = \Phi^{-1}(0.8) = 0.84 \Leftrightarrow k = 10.2$$

Teoremas da aditividade da distribuição normal

- qualquer soma (ou diferença) de v.a. Normais e independentes é ainda uma v.a. Normal.

$$X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

$$X_1 - X_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$$

- de uma forma mais geral:

$$X_i \sim N(\mu_i, \sigma_i^2), \quad \sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

- Se X_1, X_2, \dots, X_n são n v.a. Normais e independentes com o mesmo valor médio μ e a mesma variância σ^2

$$\sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2)$$

Distribuição Normal. Exemplo 3

E3. Um aluno tem duas possibilidades de se deslocar ao ISEP e o tempo de deslocação segue uma distribuição normal. Pelo caminho A o tempo de deslocação é $N(55 \text{ min}; 81 \text{ min}^2)$ enquanto que pelo caminho B é $N(60 \text{ min}; 9 \text{ min}^2)$. O aluno dispõe de 63 minutos, no máximo para realizar a viagem de modo a não chegar atrasado.

- a) Qual dos caminhos deve o aluno utilizar?
- b) Supondo que o aluno escolhe ao acaso (atirando uma moeda) um caminho qual a probabilidade de se atrasar?
- c) Calcule a probabilidade do tempo total acumulado em 4 viagens pelo caminho A e 6 viagens pelo caminho B exceder 10 horas.
- d) Calcule a probabilidade do tempo de uma viagem pelo percurso A demorar mais do que uma viagem pelo percurso B.

Distribuição Normal. Exemplo 3: Resolução

X_A —"Tempo de conclusão do percurso A(min)"; $X_A \sim N(55;81)$

X_B —"Tempo de conclusão do percurso B (min)"; $X_B \sim N(60;9)$

X_T —"Tempo total de conclusão dos 10 percursos (min)"

Resolução

a)

$$P(X_A < 63) = \Phi\left(\frac{63 - 55}{\sqrt{81}}\right) = \Phi(0.89) = 0.8133$$

$$; P(X_B < 63) = \Phi\left(\frac{63 - 60}{3}\right) = \Phi(1) = 0.8413$$

$$R: B \text{ pois } \Phi(1) > \Phi(0.89)$$

b)

$$R: 0.5P(X_A > 63) + 0.5P(X_B > 63) = 0.1727$$

c)

$$X_T = \sum_{i=1}^4 X_{Ai} + \sum_{i=1}^6 X_{Bi} \sim N(4 \cdot 55 + 6 \cdot 60; 4 \cdot 81 + 6 \cdot 9)$$

$$X_T \sim N(580; 19.44^2)$$

$$P(X_T > 600) = 1 - P(X_T \leq 600) = 1 - \Phi(1.03) = 0.1515$$

d)

$$P(X_A > X_B) = P(X_A - X_B > 0) = P(W > 0) = 1 - P(W \leq 0) =$$

$$1 - \Phi\left(\frac{0 - (-5)}{\sqrt{9 + 81}}\right) = 1 - \Phi(0.53)$$

$$= 0.2981$$

$$CA: W = X_A - X_B \sim N(55 - 60; 81 + 9) \text{ (Aditividade)}$$

Teorema do Limite Central

Sejam X_1, X_2, \dots, X_n variáveis aleatórias i.i.d. (n v.a. independentes e igualmente distribuídas) com os valores médios $\mu_1, \mu_2, \dots, \mu_n$, e variâncias $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ finitas, respetivamente. Então, para n grande (na prática para $n \geq 30$),

$$\sum_{i=1}^n X_i \approx N \left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2 \right)$$
$$\frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \approx N(0,1)$$

Exemplo

1. Admite-se que o erro cometido em cada operação de medição tem distribuição $U(-5 \text{ mm}; 5 \text{ mm})$
 - a) Caracterize a v.a. que representa o erro propagado em 100 operações de medição.
 - b) Calcule a probabilidade do erro propagado em 100 medições exceder 3 cm.

Exemplo

- a) Caracterize a v.a. que representa o erro propagado em 100 operações de medição.

X_i – Erro cometido na i –ésima medição (mm): $i = 1, 2, \dots, 100$

Y – "Erro total de 100 operações de medição"

$$Y = \sum_{i=1}^{100} X_i \sim N(100\mu; 100\sigma^2)$$

(Teorema do limite central)

Uma vez que $X \sim U(-5;5)$

$$\text{vem } \mu = \frac{a+b}{2} = \frac{-5+5}{2} = 0$$

$$\sigma^2 = \frac{(b-a)^2}{12} = \frac{(5-(-5))^2}{12} \approx 8.33$$

Assim, $Y \sim N(100 \cdot 0 + 100 \cdot 8.33)$

Aplicação do Teorema do limite central ($n \geq 30$)

- b) Calcule a probabilidade do erro propagado em 100 medições exceder 3 cm.

$$Y \sim N(0; 100 \cdot 8.33)$$

$$Y \sim N(0; 28.9^2)$$

$$P(Y > 30) = 1 - P(Y \leq 30) = 1 - \Phi\left(\frac{30 - 0}{28.9}\right) = 1 - \Phi(1.04)$$

$$= 0.1492$$